



Sofia Lima dos Santos

Atividade sobre Análise Exploratória de Dados

Considere os datasets “Amazon Sales Dataset.zip” e “Car Prices Jordan 2023.zip”.

1. Quais são os tipos das variáveis (categórica ou numérica, nominal/ordinal ou discreta/contínua)?

Variável	Tipo
product_id	qualitativa nominal
product_name	qualitativa nominal
rating	quantitativa contínua
Model	qualitativa nominal
Price	quantitativa contínua

2. Há valores ausentes? Em quais variáveis?

Sim.

Em “Amazon Sales Dataset” nas variáveis:

product_id, product_name, category, discounted_price, actual_price discount_percentage, rating, rating_count, about_product, user_id, user_name, review_id, review_title review_content, img_link, product_link.

Em “Car Prices Jordan”, nas variáveis: Model, Property, Power, Price.

3. Existem variáveis irrelevantes ou redundantes?

Irrelevantes: No dataset da Amazon, colunas como img_link e product_link são irrelevantes para uma análise estatística de preços ou avaliações, por exemplo.

Redundantes: As colunas discounted_price e actual_price junto com a discount_percentage. Se temos as duas primeiras, a terceira é um cálculo direto delas.

4. Qual é a distribuição da variável, média, mediana e moda? (Use histograma e/ou teste estatístico)

Selecione 5 variáveis para responder.



Variável	Distribuição	Média	Mediana	Moda
Price	não normal	52.647,52	39.000,00	45.000,00
Power	não normal	2.126,65	2.000,00	2.000,00
discounted_price	não normal	3.125,31	799,00	199,00
actual_price	não normal	5.444,99	1.650,00	999,00
rating	não normal	4,10	4,10	4,10

5. Em quais variáveis existem outliers? (Dica: use o gráfico *boxplot*) Caso existam, o que fazer com eles?

Existem outliers em todas as variáveis analisadas.

Em Price e Power (Carros), existem pontos bem acima do limite superior do boxplot (representando carros de altíssimo luxo e potência).

Em discounted_price e actual_price (Amazon), existe uma grande quantidade de pontos acima do limite superior (representando produtos caros, como computadores ou TVs, em meio a muitos itens baratos).

Em rating (Amazon), os outliers estão abaixo do limite inferior (produtos com notas muito baixas, como 2.0 ou 3.0, já que a maioria se concentra acima de 4.0).

6. Quais são as categorias mais frequentes (frequência absoluta)? (Dica: use gráfico de barras)

No Dataset da Amazon (Categorias de Produto):

- Electronics: 526 produtos
- Computers & Accessories: 453 produtos
- Home & Kitchen: 448 produtos

No Dataset de Carros (Marcas):

- Porsche: 51 carros
- MG: 19 carros
- Toyota e Kia: 17 carros cada

7. Existe alguma categoria dominante?

Na amazon: Não existe uma única categoria que domine absolutamente o dataset.



Nos carros: Sim, a marca Porsche é a dominante.

8. Existe tendência ao longo do tempo? (Use gráfico de linha ou de barras com linha de tendência)

No Gráfico de Linha, é possível observar uma tendência de crescimento exponencial em direção aos anos mais recentes. A maioria dos carros listados no dataset são modelos recentes (de 2019 a 2023). Há uma clara preferência do dataset em veículos seminovos e zero km.

9. Existe sazonalidade?

Como os datasets não possuem a data exata (dia/mês) em que a transação ocorreu ou em que a avaliação foi feita, não é possível determinar sazonalidade com os dados atuais.

10. Existem picos ou quedas abruptas?

Sim, olhando para a linha do tempo dos Modelos de Carro:

Pico Abrupto: Há um salto abrupto entre os modelos de 2021 (43 carros) para 2022 (106 carros), resultando no pico máximo em 2023 (154 carros).

Queda Abrupta: Logo após o pico de 2023, há uma queda nos modelos de 2024 (apenas 12 carros). Isso indica o momento temporal em que os dados foram extraídos (provavelmente durante meados de 2023), quando os modelos 2024 ainda estavam apenas começando a ser lançados ou anunciados no mercado.