

Sofia Lima dos Santos

Ciência de Dados - Atividade 03/03/2026 - Teste de Normalidade

1) Escolha um dataset com dados para avaliação (vendas, notas, etc).

Os dataset escolhidos foram: amazon_sales_dataset

2) Defina as hipóteses para testar a normalidade dos dados

Nível de significância: $\alpha = 0,05$.

Coluna *Price*

Hipótese nula (H_0): os dados de *price* seguem distribuição normal.


Hipótese alternativa (H_1): os dados de *price* não seguem distribuição normal.


Coluna *total_revenue*

H_0 : a variável *total_revenue* segue distribuição normal.



H_1 : a variável *total_revenue* não segue distribuição normal.

3) Elabore o gráfico Histograma





4) Elabore o gráfico Box plot



5) Faça o teste de Shapiro

```
> set.seed(123)
> amostra <- sample(dados$price, 5000)
> shapiro.test(amostra)
```

Shapiro-Wilk normality test

data: amostra
W = 0.95548, p-value < 2.2e-16

```
Shapiro-Wilk normality test

data:  amostra
W = 0.90448, p-value < 2.2e-16
```

(Devido ao tamanho da amostra exceder o limite do teste de Shapiro–Wilk, foram utilizadas amostras aleatórias de 5000 observações.)

6) Os dados do dataset seguem a distribuição normal? Como ficaram as hipóteses?

Os dados da coluna *price* não seguem distribuição normal.

Hipóteses após o teste:

- H_0 : os dados seguem distribuição normal: rejeitada
- H_1 : os dados não seguem distribuição normal: evidência a favor

Os dados da variável *total_revenue* não seguem distribuição normal.

Situação das hipóteses:

- H_0 : rejeitada
- H_1 : há evidências a favor

7) Justifique a decisão.

Foi aplicado o teste de Shapiro–Wilk às variáveis *price* e *total_revenue* com nível de significância de 5%. Como o p-valor obtido foi menor que 0,05, rejeita-se a hipótese nula de normalidade. Assim, podemos concluir que os dados não seguem distribuição normal. A análise visual dos histogramas também indica ausência de formato de sino, confirmando o resultado do teste.